



YAPAY ZEKA MÜHENDİSLİĞİ DERİN ÖĞRENME DERSİ PROJE RAPORU

HAVADAN GÖRÜNTÜLERDE BİNA TESPİTİ VE BÖLÜTLENMESİ

ÖĞRENCİ : ABDULLAH KENNAS

NO: 230212906

DERS SORUMLUSU :Dr. Öğr. Üyesi MURAT ŞİMŞEK

Havadan Görüntülerde Bina Tespiti ve Bölütlenmesi: Massachusetts Buildings Veri Seti Üzerinde Anlamsal (U-Net, U-Net++, DeepLabV3+) ve İnsans (Mask R-CNN) Yaklaşımların Karşılaştırmalı Analizi

Özet

Bu araştırma, havadan görüntü analizi çerçevesinde binaların otomatik tespiti ve bölütlenmesi için derin öğrenme tabanlı iki ana paradigmayı ele almaktadır. Massachusetts Buildings veri seti kullanılarak gerçekleştirilen çalışmada, ilk olarak ResNet-34 omurgasına (backbone) sahip üç farklı anlamsal bölütleme (semantic segmentation) mimarisi (U-Net, U-Net++, DeepLabV3+) karşılaştırmalı olarak analiz edilmiştir. İkinci aşamada ise, nesne bazlı (instance segmentation) yaklaşımı temsil eden ve COCO veri seti üzerinde ön-eğitilmiş ağırlıklarla başlatılan bir Mask R-CNN (ResNet-50 + FPN) hattı kurulmuştur. Deneysel bulgular, anlamsal modeller arasında U-Net++ mimarisinin 0.6558 ortalama Jaccard endeksi (IoU) ile en yüksek performansı sergilediğini ortaya koymuştur. Mask R-CNN modeli ise sadece iki epoch süren eğitim sonucunda binaları tekil nesneler olarak başarıyla ayırtmış; sınırlayıcı kutu (bounding box) seviyesinde 0.6849 AP50 ve bölütleme maskesi seviyesinde 0.6276 AP50 metriklerine ulaşmıştır. Sonuçlar, iç içe geçmiş (nested) atlama bağlantılarının anlamsal boşluğu (semantic gap) kapatmadaki etkinliğini ve transfer öğrenmenin karmaşık nesne tespiti görevlerindeki hızlandırıcı etkisini doğrulamaktadır.

1. Giriş

1.1 Motivasyon

Yüksek çözünürlüklü havadan görüntülerin otonom analizi; şehir planlama, afet yönetimi, vergilendirme sistemleri ve güncel haritacılık faaliyetleri için stratejik bir gerekliliktir. Geleneksel manuel haritalama süreçlerinin maliyetli ve zaman alıcı olması, derin öğrenme tabanlı bilgisayarlı görü algoritmalarının bu alandaki kullanımını bir zorunluluk haline getirmiştir.

1.2 Amaçlar

Bu çalışmanın temel amacı, Massachusetts Buildings veri seti üzerinde üç farklı kod çözücü (decoder) mimarisinin (U-Net, U-Net++, DeepLabV3+) performansını piksel bazlı olarak kıyaslamak ve binaları sadece maske olarak değil, tekil instanslar olarak da tespit edebilen bir Mask R-CNN hattı geliştirmektir.

1.3 Katkıları

Çalışmanın literatür ve uygulama açısından temel katkıları aşağıda maddeler halinde sunulmuştur:

- Farklı kod çözücü stratejilerinin (iç içe geçmiş bağlantılar vs. genişletilmiş evrişimler) havadan bina tespiti başarımı üzerindeki etkisi sayısal ve nitel olarak raporlanmıştır.
- Anlamsal (semantic) maskelerden instans tabanlı bir veri seti (COCO JSON formatı) türetilmiş ve nesne bazlı bir eğitim hattı oluşturulmuştur.
- Mask R-CNN gibi yüksek bellek tüketen modellerin, giriş ölçeklendirme optimizasyonu ile düşük kapasiteli donanımlarda eğitilebilirliği gösterilmiştir.
- Piksel tabanlı (semantic) ve nesne tabanlı (instance) yaklaşımların avantaj ve kısıtlamaları kapsamlı bir şekilde analiz edilmiştir.

2. İlgili Çalışmalar

Havadan görüntü bölütleme literatüründe öne çıkan mimari ve araçlar şunlardır:

- **U-Net (Ronneberger et al., 2015):** Simetrik kodlayıcı-kod çözücü yapısı ve atlama bağlantıları (skip connections) ile düşük seviyeli özelliklerin korunmasını sağlar.
- **U-Net++ (Zhou et al., 2018):** U-Net mimarisini yoğun ve iç içe geçmiş (nested) atlama yollarıyla geliştirerek, kodlayıcı ve kod çözücü arasındaki anlamsal boşluğu (semantic gap) minimize etmeyi hedefler.
- **DeepLabV3+ (Chen et al., 2018):** Çok ölçekli bağlamsal bilgiyi yakalamak için Genişletilmiş Uzamsal Piramit Havuzlama (Atrous Spatial Pyramid Pooling - ASPP) modülünü ve genişletilmiş (dilated) evrişimleri kullanır.
- **Mask R-CNN (He et al., 2017):** Nesne tespiti (Faster R-CNN) ile instans maskesi tahminini birleştiren, Bölgesel Öneri Ağı (Region Proposal Network - RPN) ve Özellik Piramit Ağı (Feature Pyramid Network - FPN) tabanlı bir mimaridir.
- **Teknik Araçlar:** Modellerin inşasında segmentation_models_pytorch kütüphanesinden, veri artırma süreçlerinde ise Albumentations (Buslaev et al.) kütüphanesinden faydalanılmıştır.

3. Veri Seti ve Ön-İşleme

3.1 Massachusetts Buildings (Mnih, 2013)

Veri seti, Boston metropoliten bölgesine ait 151 adet RGB hava görüntüsünden oluşmaktadır. Görüntüler 1500x1500 piksel boyutunda olup yaklaşık 1 m/piksel mekansal çözünürlüğe sahiptir. Etiketler, binaların bulunduğu alanları temsil eden ikili (binary) maskelerdir.

3.2 Bölünme ve Patch'leme

Kaggle üzerindeki resmi veri bölünmesi (train/val/test) korunmuştur. prepare_data.py scripti ile görüntüler 256x256 boyutunda, örtüşmeyen yamalara (patch) bölünmüştür. Bu işlem sonucunda eğitim setinde 3425, doğrulama setinde 100 ve test setinde 250 yama elde edilmiştir.

3.3 İnstans Çıkartımı

İkili maskelerden instans verisi üretmek amacıyla prepare_instance_data.py üzerinden connectedComponentsWithStats algoritması işletilmiştir. Bu işlemle binalar tekil nesnelere dönüştürülmüş ve RLE (Run-Length Encoding) formatında COCO JSON etiketleri üretilmiştir. Eğitim setinde 146,270; test setinde 11,875 tekil bina (instans) saptanmıştır. Bina içeren patch oranları eğitim setinde %88.8, test setinde %93.2 olarak kaydedilmiştir.

4. Metodoloji

4.1 Anlamsal Bölütleme Hattı

Tüm anlamsal modellerde ortak olarak ImageNet üzerinde ön-eğitilmiş **ResNet-34** kodlayıcısı kullanılmıştır. Kayıp fonksiyonu olarak, arka plan baskınlığına karşı dirençli olan "0.5 * BCEWithLogitsLoss + 0.5 * Dice" hibrit yapısı tercih edilmiştir. Adam optimizyer (lr 1e-4) ve ReduceLROnPlateau (patience 5) mekanizmasıyla eğitim optimize edilmiştir. Veri artırma (augmentation) tarafında yatay/dikey çevirme, RandomRotate90, Gauss gürültüsü ve CoarseDropout gibi teknikler uygulanmıştır.

4.2 İnstans Bölütleme Hattı

Bu hat için **Mask R-CNN (ResNet-50 + FPN v2)** mimarisi kullanılmıştır. Sınıflandırıcı ve maske kafaları "arkaplan" ve "bina" olmak üzere iki sınıf için yeniden yapılandırılmıştır. VRAM tüketimini kontrol altında tutmak amacıyla giriş boyutları min_size = max_size = 256 olarak sabitlenmiştir. Bu optimizasyon sayesinde bellek tüketimi 6 GB'tan 2.46 GB'a düşürülerek donanım verimliliği sağlanmıştır. Toplam kayıp; sınıflandırıcı, kutu regresyonu, maske, nesnellik (objectness) ve RPN kutu regresyonu kafalarının toplamından oluşmaktadır.

5. Deneysel Kurulum

Parametre,Değer

GPU,NVIDIA RTX 4070 Laptop (8 GB VRAM)

Yazılım,"PyTorch 2.6.0, torchvision 0.21.0, CUDA 12.4"

Anlamsal Parametreler,"Batch Size: 16, Max Epoch: 30, Patience: 7"

Mask R-CNN Parametreler,"Batch Size: 4, Learning Rate: 5e-4, AdamW"


Deneysel süreçte Mask R-CNN eğitimi toplam ~11.2 dakika sürmüştür. İlk epoch 331 saniye, ikinci epoch ise 340 saniye sürmüştür; en iyi doğrulama sonucu ikinci epoch sonunda elde edilmiştir.

6. Sonuçlar


6.1 Anlamsal Bölütleme Performansı

Model	Mean	Median	Std
U-Net	0.6449	0.6495	0.1779
U-Net++	0.6558	0.6674	0.1713
DeepLabV3+	0.6157	0.6172	0.1788


U-Net++ mimarisi tüm temel metriklerde (Mean, Median, ≥ 0.5 IoU) en yüksek başarıyı elde etmiştir. Şekil 1, 2 ve 3'teki dağılım analizleri, U-Net++'ın daha kararlı ve yüksek performanslı olduğunu doğrulamaktadır. Metrik tabanlı genel karşılaştırma Şekil 4 ve 5'te; eğitim süreçleri ve nitel karşılaştırmalar ise Şekil 6, 7, 8 ve 9'da sunulmuştur.




Şekil 1: Test setinde model başına ortalama IoU. Hata çubukları, 250 patch üzerinden standart sapmayı göstermektedir. U-Net++ en yüksek IoU'yu elde etmiştir.




Şekil 2: Test setindeki görüntü başına IoU dağılımı (her model için ayrı histogram). Kırmızı kesikli çizgi ortalamayı, siyah noktalı çizgi medyayı göstermektedir.




Şekil 3: U-Net, U-Net++ ve DeepLabV3+ için görüntü başına IoU dağılımlarının kutu grafiği. U-Net++ hem daha yüksek medyana hem de daha düşük yayılıma sahiptir.




Şekil 4: Üç anlamsal bölütleme modeli için test setinde IoU, Dice ve piksel doğruluğu metriklerinin karşılaştırmalı sütun grafiği.




Şekil 5: Eğitilebilir parametre sayısı (milyon) ve ortalama çıkarım gecikmesi (ms / görüntü) karşılaştırması.




Şekil 6: Aynı 5 test patch'i üzerinde nitel karşılaştırma. Sütunlar: giriş görüntüsü, ground truth maskesi, U-Net, U-Net++, DeepLabV3+ tahminleri.



Şekil 7: U-Net eğitim eğrisi. Soldan sağa: eğitim/doğrulama kaybı, doğrulama IoU ve doğrulama Dice skoru.



Şekil 8: U-Net++ eğitim eğrileri (loss, val IoU, val Dice). En istikrarlı yakınsama gözlemlenmektedir.




Şekil 9: DeepLabV3+ eğitim eğrileri (loss, val IoU, val Dice).

6.2 Nesne Tespiti ve İnstans Bölütleme (Mask R-CNN)


Mask R-CNN modeline ait COCO mAP metrikleri şu şekildedir:

Metrik	Bounding Box AP (Nesne Tespiti)	Segmentation AP (İnstans Bölütleme)
AP (Ortalama Hassasiyet)	0.2755	0.2000
AP50 (IoU=0.50)	0.6849	0.6276
AP_small (Küçük Nesneler)	0.2708	0.1973
AP_medium (Orta Nesneler)	0.4224	0.3128


Skor eşiği ≥ 0.5 olarak ayarlandığında, 11.875 bina arasından 10.670 adet bina doğru tespit edilmiştir (recall = 0.898). Eğitim süreci Şekil 10'da, COCO mAP tabanlı nicel sonuçlar Şekil 11'de, nitel tespit örnekleri ise Şekil 12 ve 13'te özetlenmektedir.



Şekil 10: Mask R-CNN eğitim eğrisi. Sol: 5 kafanın toplam kaybı (eğitim ve doğrulama). Sağ: öğrenme oranının epoch'a göre değişimi.



Şekil 11: Mask R-CNN test seti COCO mAP karşılaştırması: bbox AP (nesne tespiti) ve segm AP (instans maskesi), AP @ [.5:.95], AP50 ve AP75 eşikleri için.



Şekil 12: Test setinden nitel Mask R-CNN örnekleri. Solda ground truth kutuları ve binaların gerçek konumları, sağda model tahminleri (yeşil kutu + renkli instans maskesi + skor).



Şekil 13: Yoğun Boston mahallesi üzerinde Mask R-CNN tahmini. Sol: giriş 256x256 RGB patch'i. Sağ: skor ≥ 0.5 ile 96 bina tespiti; her bina için ayrı sınırlayıcı kutu, renkli per-instance mask ve güven skoru gösterilmiştir.

6.3 Paradigma Karşılaştırması

Piksel tabanlı anlamsal bölütleme, hesaplama açısından daha hafiftir ancak binaları tekil varlıklar olarak ayırt edemez. Mask R-CNN ise binaları nesne bazlı olarak konumlandırıp (localization) sınıflandırarak nesne sayma ve takip gibi görevlere imkan tanır. Ancak Mask R-CNN hattında instansların anlamsal maskelerden connectedComponentsWithStats ile türetilmesi, bitişik yapıların tek bir nesne olarak algılanması (under-segmentation) riskini doğurmaktadır.

7. Tartışma

1. **U-Net++ ve Anlamsal Boşluk:** U-Net++'ın U-Net ve DeepLabV3+'ı geride bırakması, yoğun iç içe geçmiş skip bağlantılarına dayandırılmaktadır. Bu yapı, kodlayıcıdaki düşük seviyeli mekansal detaylar ile kod çözücüdeki yüksek seviyeli anlamsal özellikler arasındaki boşluğu daha verimli bir şekilde kapatmaktadır.
2. **Dice + BCE Kaybı:** Bina piksellerinin nadirliği nedeniyle oluşan sınıf dengesizliği, Dice kaybının kesişim odaklı yapısıyla başarıyla yönetilmiştir.
3. **Transfer Öğrenme ve Eğitim Süresi:** Mask R-CNN'in sadece 11.2 dakikalık (2 epoch) eğitimle 0.685 bbox AP50 başarısına ulaşması, COCO ön-eğitimli ağırlıkların yüksek genelleme kapasitesinden kaynaklanmaktadır. Bu kısa sürede modelin karmaşık nesne sınırlarını öğrenebilmesi, transfer öğrenmenin önemini vurgulamaktadır.
4. **Sınırlamalar:** Şekil 13'te görüldüğü üzere yoğun kentsel alanlarda duvar paylaşılan binalar tek bir nesne olarak algılanabilmektedir. Bu durum, eğitim verisinin doğrudan instans etiketlerine sahip olmamasının bir sonucudur.

8. Sonuç ve Gelecek Çalışmalar

Bu çalışmada, Massachusetts Buildings veri seti üzerinde anlamsal ve instans bazlı derin öğrenme modelleri kapsamlı bir şekilde incelenmiştir. U-Net++, anlamsal bölütleme görevinde en yüksek performansı sergilerken, Mask R-CNN binaların tekil olarak sayılmasına imkan tanımıştır. Gelecek çalışmalarda:

- Mask R-CNN eğitim süresinin 15-20 epocha çıkarılarak AP50 skorunun 0.80+ üzerine taşınması,
- YOLOv8-seg gibi tek aşamalı (one-stage) mimarilerle hız-başarım karşılaştırması yapılması,
- Bitişik bina sorununu çözmek için watershed segmentasyonu veya morfolojik son-ışleme tekniklerinin entegrasyonu planlanmaktadır.

Kaynaklar

- Chen, L.-C., Zhu, Y., Papandreou, G., Schroff, F., & Adam, H. (2018). Encoder-Decoder with Atrous Separable Convolution for Semantic Image Segmentation. *ECCV*.
- He, K., Gkioxari, G., Dollár, P., & Girshick, R. (2017). Mask R-CNN. *ICCV*.
- Mnih, V. (2013). *Machine Learning for Aerial Image Labeling*. PhD thesis, University of Toronto.
- Ronneberger, O., Fischer, P., & Brox, T. (2015). U-Net: Convolutional Networks for Biomedical Image Segmentation. *MICCAI*.
- Zhou, Z., Siddiquee, M. M. R., Tajbakhsh, N., & Liang, J. (2018). UNet++: A Nested U-Net Architecture for Medical Image Segmentation. *DLMIA*.

Ekler

Ek A - Proje Dosya Yapısı

```
.
├── prepare_data.py           # Patchleme scripti
├── prepare_instance_data.py  # COCO JSON üretimi
├── dataset.py               # Anlamsal Dataset sınıfı
├── dataset_instance.py      # Mask R-CNN Dataset sınıfı
├── train.py                 # Anlamsal eğitim
├── train_instance.py        # Mask R-CNN eğitim
├── evaluate.py              # Anlamsal test
├── evaluate_instance.py     # Mask R-CNN test (COCO mAP)
├── models/                  # Kayıtlı modeller (.pth)
└── outputs/                 # Tahminler ve grafikler
```

Ek B - Yeniden Üretim Komutları

1. `pip install -r requirements.txt`
2. `python prepare_data.py --raw_dir ./mass_buildings`
3. `python prepare_instance_data.py`
4. `python train.py --model unet++`
5. `python train_instance.py`
6. `python evaluate_instance.py`
7. `python predict_instance.py --image test_patch.jpg`